


Les Fournisseurs d'API :



Petite introduction je vais beaucoup parler de «tokens » en gros une IA elle est limitée en texte maximum qu'elle peut recevoir et envoyer, c'est pas compté en nombre de mots ou caractères mais en « tokens ». Et un token ça vaut approximativement 0.75 mots. Je vais vérifier. Bon c'est 0.75 mots Anglais du coup un token ça vaut environ 0.5 mots Français soit 2 tokens par mots environ.



Mistral AI:

<https://mistral.ai/>

Du coup le truc bien avec leur API, c'est que il y a beaucoup de modèles gratuits j'ai compté il y en a 24 au total.

Chez Mistral ya deux limites tout

d'abord en forfait gratuit t'as le droit a 60 requêtes par minutes (60 RPM)

Et t'as une limite propre a chaque modèle donc par exemple le modèle

codestral-2508 l'IA peut te renvoyer 625 000 tokens par minutes (TPM) et tu peux lui faire 2.08 requêtes par secondes (RPS) et si tu veux consulter la limite de chaque modèle exact :

<https://admin.mistral.ai/plateforme/limits> (tu peux publier leur API sur github dans un code ils vont pas te la supprimer)

Ensuite du coup Mistral AI ce qu'ils proposent c'est des modèles :

text to text , image to text (et aussi quand je dis image to text tu peux lui envoyer du texte + une image genre tu lui donnes une image d'un exo de maths et tu lui dis fais la question 4) et text to audio (au final c'est pas du text to voice les deux se disent mais ils disent d'avantage text to audio)

Si tu veux je te fais un tableau avec tous leurs modèles actuellement :

Modèle	Type	TPM	RPS
codestral-2508	TTT	625 000	2.08
codestral-embed	Embedding	50 000	1.00
devstral-2512	TTT	1 000 000	0.83
labs-leanstral-2603	TTT	5 000 000	0.63
magistral-medium-2509	TTT (Raisonnement)	75 000	0.08
magistral-small-2509	TTT (Raisonnement)	25 000	0.03
ministral-14b-2512	TTT	937 500	0.50
ministral-3b-2512	TTT	1 300 000	12.50
ministral-8b-2512	TTT	625 000	3.13
mistral-embed-2312	Embedding	20 000 000	1.00
mistral-large-2512	TTT	250 000	0.07
mistral-medium-2505	TTT	375 000	0.42
mistral-medium-2508	TTT	356 250	0.38

Modèle	Type	TPM	RPS
mistral-medium-latest	TTT	25 000	0.83
mistral-moderation-2411	Modération de contenu	50 000	1.67
mistral-moderation-2603	Modération de contenu	50 000	1.67
mistral-small-2506	TTT	2 250 000	5.00
mistral-small-2603	TTT	50 000	0.83
open-mistral-nemo	TTT	500 000	0.50
voxtral-mini-2507	STT	50 000	1.00
voxtral-mini-2602	STT	50 000	1.00
voxtral-mini-transcribe-realtime-2602	STT (Realtime)	50 000	1.00
voxtral-mini-tts-2603	TTS	50 000	1.00
voxtral-small-2507	STT	50 000	1.00

TTT : text to text

STT : speech to text (audio to text en gros)

TTS : text to speech

Embedding : c'est complexe a comprendre mais je crois que c'est les modèles qui convertissent du texte en neurones genre quand tu parles a une IA et qu'elle apprend des trucs sur toi elle fait des liens entre les informations (ma definition est a vérifier mdr)

Moderation : c'est un modèle qui va classer du texte en catégories genre des commentaires sur un site , il va les catégoriser en haineux ; gentil et tout .

Sur le mois de Juin j'ai consommé au total 399 680 tokens soit 200 000 mots environ.

Voilà voilà .



Groq :

<https://console.groq.com/home> (c'est le lien que j'utilise mais c'est pas leur page de présentation)

Alors je vais faire plus simple que Mistral AI, ce qu'il faut savoir pour eux, c'est qu'ils achètent des modèles d'IA et juste ils les améliorent au max pour les rendre le plus rapide au monde. Ils ont apparemment une dizaine de modèles pour les gens qui payent pas mais j'en ai fait fonctionner que deux...

Ce qu'il faut savoir sur les limites de leur API déjà ils t'offrent 30 requêtes par minutes sur TOUS leurs modèles c'est pas comme mistral ou chacun est différent la c'est tout le monde carré. Et tu peux pas publier leur API dans un code sur github sinon github leur envoie un petit message et ils te la suppriment juste et tu dois en recréer une mais le temps qu'ils la suppriment et tout j'ai constaté qu'en moyenne ils mettent 3 jours a te la révoquer.

J'ai regardé les statistiques des deux modèles d'IA que j'utilise avec groq sur Wikimind et du coup voici les stats :

Nom :	Type :	Temps moyen :	CPS :
llama-3.1-8b-instant	TTT	206ms	549
llama-3.3-70b-versatile	TTT	498ms	464

CPS : Caractères par secondes , oui je mesure en caractères par secondes moi mdr c'est plus simple, mais de toute façon si tu veux voir toutes les statistiques des modèles de Wikimind voici le lien : <https://chpalitom09-bot.github.io/Wikimind-5/models-stat.html>

Depuis le 10 Juin : j'ai utilisé 26 700 tokens ça fait 13 350 mots générés ?



Cerebras systems :

<https://cerebras.ai>

En gros c'est à peu près pareil, ils ont des modèles ils prétendent avoir les modèles les plus rapides au monde mais c'est pas ce que je constate, c'est pareil que groq j'ai réussi à faire marcher que 2 modèles je te mets les statistiques en dessous.

Pour les limites avec cerebras on a que le droit à 5 requêtes par minutes (RPM) avec un maximum de 30 000 Tokens par minutes (TPM) et un maximum de 1 000 000 tokens par jour (TPD)

Et genre en une requête tu peux lui envoyer maximum 65 000 tokens pour être précis :


Nom :	RPM max (minutes)	RPH max (heures)	RPD (jour)
gpt-oss-120b	5	150	2400
zai-glm-4.7	5	150	2400

C'est pas linéaire en gros je suis sensé avoir 300 requêtes par heures si j'utilise mes 5 par minutes. genre si tu lui envoies un texte de environ 32 500 mots il va te renvoyer un message d'erreur, et il te renverra au maximum 30 000 à 32 000 tokens par réponse.

Pour ses temps de réponses sur : <https://chpalitom09-bot.github.io/Wikimind-5/models-stat.html> on peut voir que les statistiques des deux modèles sont les suivantes :

Nom :	Type :	Temps moyen :	CPS :
gpt-oss-120b	TTT	655ms	163
zai-glm-4.7	TTT	3600ms (3.6s)	34

Honnêtement les résultats sont décevants, et si on regarde combien j'ai consommé de tokens en juin j'ai consommé : 13 540 tokens.



Pollinations AI:

<https://pollinations.ai/>

Ce qui est fort chez eux c'est qu'ils ont plein de modèles disponibles et on va dire que ya beau avoir plein de modèles.

En free ya 7 modèles text to image (TTI), ya 1 modèle de génération de vidéo (TTV) (le modèle coute 0.005 pollen/seconde de vidéo, du coup avec 0.4 pollens par heure (mon forfait actuel) je peux faire 80 secondes de vidéo par heure, ya 4 modèles text to speech (TTS), ya un modèle realtime, ya 39 modèles text to text (TTT) dont chatgpt 5.5 (le dernier modèle de OpenAI) et ya 4 modèles embedding.

Pour les limites en gratuit t'as plusieurs limites tout d'abord si tu as un compte normalement t'as le droit à 0.01 pollens / heure en gros ça équivaut à 5 images générées par heure avec leur modèle le plus économique. Ensuite si tu réunis beaucoup de conditions (compte ancien, interactions avec leur projet et tout) tu passes en supérieur et tu gagnes 0.15 pollens / heures. Ça fait hmmm 3 images générées par le modèle de chat gpt 1.5 qui fait des excellentes images (actuellement chatgpt sont au modèle 2.0 sur les images) et si tu crées une APP et que tu la publies tu es promu au max t'as 0.4 pollens par heure ça fait 222 images par heures avec leur modèle le plus économique ou environ 10 images avec gpt 1.5.

La seule limite de requêtes c'est ton pollen du coup. Tu peux aussi payer du pollen. Je sais que pour l'instant ça coute 1\$ le pollen soit 0.9€ le pollen, mais j'ai vu que le 22 Juin ils allaient refaire tout le système de pollen, les prix vont baisser de 40 à 50 %.

Et j'ai consommé un total de 0.3127 pollen c'est même pas ce que j'ai en une heure mais c'est juste aujourd'hui ça.



Tavily AI:

<https://www.tavily.com/>

Alors sur cette IA tu vas pas avoir autant de descriptions (en vrai c'est tout benef pour toi) car je suis pas autant renseigné, j'utilise depuis quelques mois mais genre je l'utilise pour une fonctionnalité. Du coup quand un modèle d'IA n'est entraîné depuis longtemps genre les modèles de mistral je sais que c'est de Octobre 2023 à 2024 du coup baaah les questions d'actualité elles connaissent pas et je me sers de Tavily pour poser des questions sur l'actualité et tout.

Du coup pour la limite c'est 1000 requêtes par mois.

Jina AI:

<https://jina.ai/reader/>

Donc pour cette application ya plein d'options moi j'utilise leur API sans clé pour lire des liens et redonner le contenu à mon IA dans un fichier texte (au format markdown c'est un fichier texte avec de la mise en page) genre ya des API tu dois forcément les utiliser avec une clé par exemple groq : gsk_28728732837 mais eux tu peux utiliser avec et sans clé, donc sans clé API ce que ça offre c'est 20 RPM en liens genre 20 liens par minutes c'est extra beaucoup. Et si j'utilise leur API j'ai le droit à 500 requêtes par minutes sans payer.



Voici une screen des limites sans API key et avec API key gratuite :

Product	API Endpoint	Description	w/o API Key	w/ Free API Key
 Reader API	https://r.jina.ai	Convert URL to LLM-friendly text	20 RPM	500 RPM
 Reader API	https://s.jina.ai	Search the web and convert results to LLM-friendly text	⚡	100 RPM
 Embedding API	https://api.jina.ai/v1/embeddings	Convert text/images to fixed-length vectors	⚡	100 RPM & 100,000 TPM
 Reranker API	https://api.jina.ai/v1/rerank	Rank documents by query	⚡	100 RPM & 100,000 TPM
 Classifier API	https://api.jina.ai/v1/train	Train a classifier using labeled examples	⚡	25 RPM & 25,000 TPM
 Classifier API (few-shot)	https://api.jina.ai/v1/classify	Classify inputs using a trained few-shot classifier	⚡	25 RPM & 25,000 TPM
 Classifier API (zero-shot)	https://api.jina.ai/v1/classify	Classify inputs using zero-shot classification	⚡	25 RPM & 25,000 TPM
 Segmenter API	https://api.jina.ai/v1/segment	Tokenize and segment long text	20 RPM	200 RPM
 DeepSearch	https://deepsearch.jina.ai/v1/chat/completions	Reason, search and iterate to find the best answer	⚡	50 RPM

Et évidemment RPM ça reste requêtes par minutes et TPM tokens par minutes. Eux ils ont un fonctionnement spécifique. En gros tu as pas de tokens tous les jours qu'ils te donnent ou tous les mois, c'est dès que tu crées un compte tu as un nombre de tokens, ils te donnent 10 000 000 de tokens et ensuite dès que tu as utilisé tes tokens gratuits faut soit baaaah que tu utilises leur API sans clé soit tu payes, c'est pour ça que je l'intègre pas a Wikimind j'ai déjà 20 applications IA connectées je peux pas tout surveiller et changer tout ça tout seul .




Google AI Studio API :

<https://aistudio.google.com/>

Alors déjà petit commentaire sur leur nouveau logo qui est salement moche par rapport a avant 🤔🤔 je le trouve dégueulasse. Je te met a droite l'ancien et a gauche le nouveau. Déjà pour ça ils perdent un point. Ensuite c'était la première API de toute ma vie que j'ai utilisée j'étais obligé de la mentionner. Alors franchement c'est une très bonne API. C'est clean, ils ont des bons modèles je me souviens au début c'était facile d'utilisation à mettre dans un code mais c'est devenu hyper

dur et en plus vu que c'est google et qu'ils ont interdit de publier leur API dans github ou des trucs comme ça baaaah dès que tu la publies ils la suppriment donc ça devient nul a utiliser. Même si ya une technique pour cacher ta clé des bots qui détectent :




En gros imaginons ma clé API c'est google-f7bfkkoirrvbzbpa08 :
Ce que je vais faire dans mon code c'est au lieu de définir ma fonction par
"apiKey": {

```
    "google_appi_key " : "google-f7bfkkoirrvbzbpa08"
```

Je vais faire

```
"apiKey": {  
    "google_appi_key " : "g1" + "g2" + "g3"  
    "g1 " : "google-"  
    "g2 " : "f7bfkkoirr"  
    "g3 " : "vbzbpa08"
```

C'est un exemple hein mais tu fais une addition et le bot lui il va chercher la combinaison exacte de la clé : google-f7bfkkoirrvbzbpa08 du coup baaaah t'as juste a faire en plusieurs parties et t'es tranquille !!! Mais on verra la partie technique plus tard.



SambaNova API :

<https://sambanova.ai>

Donc eux ils proposent des modèles puissants, la différence avec les autres IA c'est que eux ils proposent pas une limite genre 30 RPM ou des trucs comme ça ils te donnent 5\$ valides pour moins de 3 mois et tu consommes et une fois que tu as tout consommé baaaah t'es baisé.. Créé un deuxième compte mdr. J'ai pas rencontré d'énormes soucis à intégrer leur API mais c'était la plus dure.. Si tu veux je te met le tableau avec leurs modèles et les prix. Parce que

du coup quand tu fais des requêtes tu consommes de tes 5\$. Du coup au final j'en ai pas parlé car j'ai parlé que des trucs gratuits mais ils proposent des prix au Million de tokens.

Donc comme je te l'avais déjà dit 2 token c'est environ 1 mot en français et 0.75 mots anglais. Du coup 1M Tokens c'est 500 000 mots environ ça te laisse quand même une bonne marge. Sauf que du coup ils te donnent un prix pour 1M de tokens d'entrée et 1M de tokens de sortie.

En entrée t'as les messages de l'utilisateur et en sortie ceux de l'IA genre si l'utilisateur envoie un giga long texte qui fait 1000 mots baaaah ça fera 2000 tokens, ils vont déjà te faire payer ça. Et si l'IA te répond 5000 mots baaaaah ça va faire 1000 tokens du coup ils rajoutent au prix le prix des tokens de sortie.

Model	Input (per 1M tokens)	Output (per 1M tokens)
DeepSeek-R1-Distill-Llama-70B	0.70 USD	1.40 USD
DeepSeek-V3.1-cb	0.15 USD	0.75 USD
DeepSeek-V3.1	3 USD	4.50 USD
DeepSeek-V3.2	3 USD	4.50 USD
gemma-4-31B-it	0.38 USD	1.15 USD
gpt-oss-120b	0.22 USD	0.59 USD
Meta-Llama-3.3-70B-Instruct	0.60 USD	1.20 USD
MiniMax-M2.7	0.60 USD	2.40 USD

Donc par exemple avec le modèle DeepSeek-V3.2 :

L'utilisateur envoie une demande qui fait 50 mots, on convertit en tokens on dit que ça fait à peu près 100 tokens. On regarde le prix pour 1M tokens : 3\$.

Du coup le message de l'utilisateur va coûter $\frac{3}{1\,000\,000} \times 100$ donc 0.0003\$ Le message tu vois ça va mais là on va dire que c'est simulatif car en fait l'utilisateur envoie pas que 100 tokens vu qu'on envoie ce que la mémoire permanente a sur lui donc prénom, nom, âge, etc etc et t'es à minimum 500 Tokens par message soit 0.0015\$ Juste pour le message de l'utilisateur.

ET ENSUITE t'as le prix de l'IA qui est entre 1.5x à 4x supérieur au prix d'entrée ça dépend des modèles, parfois c'est le même prix parfois c'est 10x plus cher.

Si la réponse de l'IA fait 500 mots on a 1000 tokens en moyenne avec un prix ici là de 4.5\$ /M token. Ainsi $\frac{4.5}{1\,000\,000} \times 1000$ ça fait 0.0045

Puis t'additionne le tout ça te donne le prix du message utilisateur + message IA soit ici 0.0060\$ donc en deux messages (2 messages d'utilisateurs + 2 réponses IA) tu vas être en moyenne à 0.01\$.



Cohere API :

<https://dashboard.cohere.com/billing?tab=payment>

Je t'ai mis le premier lien que j'ai trouvé dans mon historique désolé 🙄
Alors Cohere à l'heure actuel c'est intégré à Wikimind, ça marche mais c'est pas intégré depuis longtemps alors j'ai pas vraiment d'avis, je trouve que leur modèle ne bug pas énormément parfois oui. Il consomme beaucoup de Tokens si tu payes à l'usage* genre si tu veux comme exemple j'ai testé sans mémoire et tout j'ai regardé les statistiques pour 9 Tokens d'entrée il m'a sorti 1700 tokens donc euuh ça consomme :


Endpoint	Model Type	Quantity	Unit	Total	Date (UTC)
Chat Trial	Default	1,716	Output tokens	0.00 USD	Jun 16, 2026
Chat Trial	Default	9	Input tokens	0.00 USD	Jun 16, 2026

Les limites : en Free la seule limite que je connais est de 1000 requêtes par mois, donc si tu l'intègres comme modèle secondaire à ton site si tu en fais un baaaah vaut mieux le mettre en modèle secondaire, même moi sur Wikimind on est pas à 1000 requêtes par Mois mais je suis pas référencé dans google, les gens ont du avoir un lien pour me trouver . Je te met la liste de leurs modèles ça se trouve ça t'intéresse pas mais tu peux avoir une idée un peu de ce qui existe :

Model	Trial rate limit	Production rate limit
Command A+	20 req / min	Contact
Command A Reasoning	20 req / min	Contact
Command A Translate	20 req / min	Contact
Command A Vision	20 req / min	Contact
Command A	20 req / min	500 req / min
Command R+	20 req / min	500 req / min
Command R	20 req / min	500 req / min
Command R7B	20 req / min	500 req / min
North Mini Code	20 req / min	500 req / min

Donc tu peux regarder les deux côtés du tableau mais le côté qui nous intéresse nous c'est Trial rate limit, l'autre côté c'est le côté payant .

* = Payer à l'usage quand tu payes ce que tu consommes genre tu consommes 5 Tokens très bien tu les payes, tu consommes 0 ? Tu payes 0. Et à la fin de chaque mois ça te fait un prélèvement.



WIKIMIND AL:

J'étais obligé de faire une partie sur Wikimind .. Alors ici on va pas parler d'API mais on va parler de prendre en main les IA genre comment les utiliser et tout, ce qui est bien avec Wikimind c'est que ça réunit un maximum d'options disponibles sur les autres IA et en sachant utiliser Wikimind tu sauras utiliser la majorité des IA d'aujourd'hui.

Pour l'IA clique directement sur ce lien : <https://chpalitom09-bot.github.io/Wikimind-5/>

(cette partie peut aussi servir pour les fonctionnalités que tu peux mettre dans un site que tu vas créer et ça va te permettre de comprendre le fonctionnement de chacun)

Donc t'arrives sur l'IA comme chaque IA tu vas avoir un compte à créer (normalement j'oublie pas de mettre la screen, mais je suis en train de refaire totalement l'interface de connexion a son compte) Mais du coup baaah tu dois te créer un compte alors t'en as déjà un sur Wikimind .

Souvent si tu t'inscris avec un mail et pas avec google tu auras besoin