

Les Fournisseurs d'API :

Petite introduction je vais beaucoup parler de «tokens » en gros une IA elle est limitée en texte maximum qu'elle peut recevoir et envoyer, c'est pas compté en nombre de mots ou caractères mais en « tokens ». Et un token ça vaut approximativement 0.75 mots. Je vais vérifier. Bon c'est 0.75 mots Anglais du coup un token ça vaut environ 0.5 mots Français soit 2 tokens par mots environ.



Mistral AI:

<https://mistral.ai/>

Du coup le truc bien avec leur API, c'est que il y a beaucoup de modèles gratuits j'ai compté il y en a 24 au total.

Chez Mistral ya deux limites tout

d'abord en forfait gratuit t'as le droit a 60 requêtes par minutes (60 RPM)

Et t'as une limite propre a chaque modèle donc par exemple le modèle

codestral-2508 l'IA peut te renvoyer 625 000 tokens par minutes (TPM) et tu peux lui faire

2.08 requêtes par secondes (RPS) et si tu veux consulter la limite de chaque modèle exact :

<https://admin.mistral.ai/plateforme/limits> (tu peux publier leur API sur github dans un code ils vont pas te la supprimer)

Ensuite du coup Mistral AI ce qu'ils proposent c'est des modèles :

text to text , image to text (et aussi quand je dis image to text tu peux lui envoyer du texte + une image genre tu lui donnes une image d'un exo de maths et tu lui dis fais la question 4) et text to audio (au final c'est pas du text to voice les deux se disent mais ils disent d'avantage text to audio)

Si tu veux je te fais un tableau avec tous leurs modèles actuellement :

Modèle	Type	TPM	RPS
codestral-2508	TTT	625 000	2.08
codestral-embed	Embedding	50 000	1.00
devstral-2512	TTT	1 000 000	0.83
labs-leanstral-2603	TTT	5 000 000	0.63
magistral-medium-2509	TTT (Raisonnement)	75 000	0.08
magistral-small-2509	TTT (Raisonnement)	25 000	0.03
ministral-14b-2512	TTT	937 500	0.50
ministral-3b-2512	TTT	1 300 000	12.50
ministral-8b-2512	TTT	625 000	3.13
mistral-embed-2312	Embedding	20 000 000	1.00
mistral-large-2512	TTT	250 000	0.07
mistral-medium-2505	TTT	375 000	0.42
mistral-medium-2508	TTT	356 250	0.38
mistral-medium-latest	TTT	25 000	0.83
mistral-moderation-2411	Modération de contenu	50 000	1.67
mistral-moderation-2603	Modération de contenu	50 000	1.67
mistral-small-2506	TTT	2 250 000	5.00

Modèle	Type	TPM	RPS
mistral-small-2603	TTT	50 000	0.83
open-mistral-nemo	TTT	500 000	0.50
voxtral-mini-2507	STT	50 000	1.00
voxtral-mini-2602	STT	50 000	1.00
voxtral-mini-transcribe-realtime-2602	STT (Realtime)	50 000	1.00
voxtral-mini-tts-2603	TTS	50 000	1.00
voxtral-small-2507	STT	50 000	1.00

TTT : text to text

STT : speech to text (audio to text en gros)

TTS : text to speech

Embedding : c'est complexe a comprendre mais je crois que c'est les modèles qui convertissent du texte en neurones genre quand tu parles a une IA et qu'elle apprend des trucs sur toi elle fait des liens entre les informations (ma definition est a vérifier mdr)

Moderation : c'est un modèle qui va classer du texte en catégories genre des commentaires sur un site , il va les catégoriser en haineux ; gentil et tout .

Sur le mois de Juin j'ai consommé au total 399 680 tokens soit 200 000 mots environ.

Voilà voilà .



Groq :

<https://console.groq.com/home> (c'est le lien que j'utilise mais c'est pas leur page de présentation)

Alors je vais faire plus simple que Mistral AI, ce qu'il faut savoir pour eux, c'est qu'ils achètent des modèles d'IA et juste ils les améliorent au max pour les rendre le plus rapide au monde. Ils ont apparemment une dizaine de modèles pour les gens qui payent pas mais j'en ai fait fonctionner que deux...

Ce qu'il faut savoir sur les limites de leur API déjà ils t'offrent 30 requêtes par minutes sur TOUS leurs modèles c'est pas comme mistral ou chacun est différent la c'est tout le monde carré. Et tu peux pas publier leur API dans un code sur github sinon github leur envoie un petit message et ils te la suppriment juste et tu dois en recréer une mais le temps qu'ils la suppriment et tout j'ai constaté qu'en moyenne ils mettent 3 jours a te la révoquer.

J'ai regardé les statistiques des deux modèles d'IA que j'utilise avec groq sur Wikimind et du coup voici les stats :

Nom :	Type :	Temps moyen :	CPS :
llama-3.1-8b-instant	TTT	206ms	549
llama-3.3-70b-versatile	TTT	498ms	464

CPS : Caractères par secondes , oui je mesure en caractères par secondes moi mdr c'est plus simple, mais de toute façon si tu veux voir toutes les statistiques des modèles de Wikimind voici le lien : <https://chpalitom09-bot.github.io/Wikimind-5/models-stat.html>

Depuis le 10 Juin : j'ai utilisé 26 700 tokens ça fait 13 350 mots générés ?



Cerebras systems :

<https://cerebras.ai>

En gros c'est à peu près pareil, ils ont des modèles ils prétendent avoir les modèles les plus rapides au monde mais c'est pas ce que je constate, c'est pareil que groq j'ai réussi à faire marcher que 2 modèles je te mets les statistiques en dessous.

Pour les limites avec cerebras on a que le droit à 5 requêtes par minutes (RPM) avec un maximum de 30 000 Tokens par minutes (TPM) et un maximum de 1 000 000 tokens par jour (TPD)

Et genre en une requête tu peux lui envoyer maximum 65 000 tokens pour être précis :


Nom :	RPM max (minutes)	RPH max (heures)	RPD (jour)
gpt-oss-120b	5	150	2400
zai-glm-4.7	5	150	2400

C'est pas linéaire en gros je suis sensé avoir 300 requêtes par heures si j'utilise mes 5 par minutes. genre si tu lui envoies un texte de environ 32 500 mots il va te renvoyer un message d'erreur, et il te renverra au maximum 30 000 à 32 000 tokens par réponse.

Pour ses temps de réponses sur : <https://chpalitom09-bot.github.io/Wikimind-5/models-stat.html> on peut voir que les statistiques des deux modèles sont les suivantes :

Nom :	Type :	Temps moyen :	CPS :
gpt-oss-120b	TTT	655ms	163
zai-glm-4.7	TTT	3600ms (3.6s)	34

Honnêtement les résultats sont décevants, et si on regarde combien j'ai consommé de tokens en juin j'ai consommé : 13 540 tokens.



Pollinations AI :

<https://pollinations.ai/>

Ce qui est fort chez eux c'est qu'ils ont plein de modèles disponibles et on va dire que ya beau avoir plein de modèles.

En free ya 7 modèles text to image (TTI), ya 1 modèle de génération de vidéo (TTV) (le modèle coute 0.005 pollen/secondes de vidéo, du coup avec 0.4 pollens par heure (mon forfait actuel) je peux faire 80 secondes de vidéo par heure, ya 4 modèles text to speech (TTS), ya un modèle realtime , ya 39 modèles text to text (TTT) dont chatgpt 5.5 (le dernier modèle de OpenAI) et ya 4 modèles embedding.

Pour les limites en gratuit t'as plusieurs limites tout d'abord si tu as un compte normalement t'as le droit à 0.01 pollens / heure en gros ça équivaut à 5 images générées par heure avec leur modèle le plus économique. Ensuite si tu réunis beaucoup de conditions (compte ancien , interactions avec

leur projet et tout) tu passes en supérieur et tu gagnes 0.15 pollens / heures. Ca fait hmmm 3 images générées par le modèle de chat gpt 1.5 qui fait des excellentes images (actuellement chatgpt sont au modèle 2.0 sur les images) et si tu crées une APP et que tu la publies tu es promu au max t'as 0.4 pollens par heure ça fait 222 images par heures avec leur modèle le plus économique ou environ 10 images avec gpt 1.5.